

Por que a nuvem é barata — e quando ela deixa de ser

Economia em escala, despesa de capital contra despesa operacional, e as sete estratégias de migração de sistemas legados.

O que veremos hoje

BLOCO 1

A máquina por trás do preço

Virtualização, multilocação, contêineres e multiplexação estatística. **Por que** a nuvem consegue cobrar menos do que custa o seu próprio servidor.

BLOCO 2

O preço

Despesa de capital contra despesa operacional, custo total de propriedade, as quatro formas de comprar e os quatro lugares por onde a fatura vaza.

BLOCO 3

A decisão de migrar

O ponto de equilíbrio entre as duas contas e as sete estratégias de migração de sistemas legados.

BLOCO 4

A conta de quem saiu

Um caso real, com números públicos, de uma empresa que fez o caminho inverso e voltou para o servidor próprio.

POR QUE ESTA AULA IMPORTA

Nas duas primeiras aulas vocês aprenderam **o que é** a nuvem e **de quem é a culpa** quando algo dá errado nela. Falta a pergunta que aparece em toda reunião de verdade: **quanto custa, e vale a pena?**

Quem sabe subir um servidor e não sabe defender a conta na frente de quem assina não decide nada. Hoje a aula fecha esse buraco: primeiro o mecanismo técnico que produz o preço, depois o preço, e por fim a decisão.

Formato de hoje: aula expositiva, sem prática no computador. A prática na AWS começa no próximo encontro, dia 10 de setembro.

O que faz uma coisa ser nuvem

As cinco características essenciais do NIST. Faltando qualquer uma delas, é hospedagem tradicional com nome novo.

01

Autoatendimento sob demanda

Você pede sozinho, pelo painel, sem abrir chamado.

02

Amplo acesso pela rede

De qualquer lugar, por qualquer aparelho.

03

Agrupamento de recursos

A máquina física é dividida entre vários clientes. **É o que a aula de hoje explica por dentro.**

04

Elasticidade rápida

A capacidade cresce e encolhe conforme a demanda.

05

Serviço medido

Tudo é contado e cobrado por uso.

MODELO DE IMPLANTAÇÃO	QUEM USA A INFRAESTRUTURA	EXEMPLO TÍPICO
Pública	Qualquer cliente, compartilhando o mesmo parque de máquinas	AWS, Azure, Google Cloud
Privada	Uma organização sozinha, geralmente por exigência legal	Data center próprio de um banco
Comunitária	Um grupo com a mesma exigência regulatória	Consórcio de hospitais, tribunais
Híbrida	Duas ou mais das anteriores, conectadas entre si	Dado sensível dentro, site fora

O modelo de implantação responde **ONDE** a infraestrutura fica. A camada de serviço responde **O QUE** o provedor entrega pronto. São duas perguntas independentes.

As camadas de serviço e a linha da culpa

A pilha de responsabilidades. Cada linha é uma peça que alguém precisa operar. A camada define onde passa o corte.

PEÇA	IAAS	PAAS	SAAS
Aplicação	you	you	provider
Dados	you	you	you
Runtime e bibliotecas	you	provider	provider
Sistema operacional	you	provider	provider
Virtualização	provider	provider	provider
Servidor, disco e rede física	provider	provider	provider

A linha destacada é a única que nunca muda de coluna: o dado é sempre seu.

Responsabilidade compartilhada

A AWS separa em duas frases: segurança **DA** nuvem é do provedor; segurança **NA** nuvem é sua.

Do provedor: prédio, energia, hardware, isolamento entre clientes.
Sua: quem tem acesso, quais portas abrem, se o dado está criptografado, se o arquivo ficou público.

Capital One, 2019: 106 milhões de pessoas afetadas, US\$ 80 milhões de multa. Nenhuma falha do provedor — três itens da coluna do cliente.

A camada que você escolhe decide **quanto trabalho sobra para você e de quem é a culpa** quando dá errado. Hoje entra a terceira consequência da mesma escolha: **quanto ela custa.**

Três perguntas sobre a mesma escolha

Escolher uma camada de serviço não é uma decisão técnica isolada. Ela responde a três perguntas de uma vez, e nós já respondemos duas.

AULAS 1 E 2 · RESPONDIDO

O que eu recebo pronto?

Infraestrutura, plataforma ou software. Quanto mais alta a camada, menos trabalho operacional sobra — e menos controle você tem.

AULA 2 · RESPONDIDO

De quem é a culpa?

A camada define onde passa a linha de responsabilidade. O dado, a identidade e a configuração ficam sempre do lado do cliente.

HOJE · EM ABERTO

Quanto custa, e vale a pena?

É a pergunta que aparece em toda reunião de verdade — e a que ninguém responde sem entender **por que** a nuvem cobra o que cobra.

Até aqui, as cinco características do NIST foram uma **lista para decorar**. Hoje elas viram **explicação**: você entende o mecanismo técnico que produz o preço, e só depois discute o preço.

Por que isso vale para a carreira de vocês: provisionar recurso é a metade fácil da competência. A metade que diferencia é saber quanto aquilo custa, defender a estimativa na frente de quem assina, e reconhecer quando a resposta certa é não migrar.

Se a nuvem é o computador de outra pessoa, por que o computador dela é mais barato que o meu?

Ela compra o mesmo tipo de servidor, paga a mesma energia e contrata gente que custa mais caro que a nossa. Ainda assim, alugar dela sai mais barato do que comprar o nosso. Alguma coisa nessa conta precisa ser explicada — e a explicação não é desconto por volume.

BLOCO 1

A máquina por trás do preço

Virtualização, multilocação, contêineres, multiplexação estatística e a diferença entre escalar e ser elástico. A economia da nuvem é consequência técnica.

Virtualização

Técnica que permite que **um único computador físico execute vários computadores completos e isolados** ao mesmo tempo, cada um com seu próprio sistema operacional.

A peça que faz isso chama-se **hipervisor** (*hypervisor*): um programa que divide processador, memória, disco e rede entre as máquinas virtuais e impede que uma enxergue a outra.

Hipervisor tipo 1 (*bare metal — metal nu*)

- Roda direto sobre o hardware, sem sistema operacional embaixo
- É o que todo provedor de nuvem usa
- Exemplos: KVM, Xen, VMware ESXi

Hipervisor tipo 2 (*hosted — hospedado*)

- Roda como um programa dentro do seu sistema operacional
- É o que você instala no próprio notebook
- Exemplos: VirtualBox, VMware Workstation

Uma máquina virtual (*virtual machine, VM*) é, no fim das contas, um conjunto de arquivos. Por isso ela sobe em segundos, é copiada, movida entre servidores e destruída sem que ninguém abra um parafuso.

A característica 3 do NIST — agrupamento de recursos (resource pooling) — não é promessa comercial. É consequência disto. · NIST SP 800-145, 2011

Um servidor físico, quatro clientes que não se conhecem



Cada cliente enxerga "o seu servidor": liga, desliga, instala o que quiser, reinicia. Nenhum sabe que existem outros três na mesma máquina, e nenhum consegue ler a memória ou o disco do vizinho.

É aqui que o preço nasce. O provedor comprou um servidor e o está alugando quatro vezes. Se cada cliente comprasse a própria máquina, seriam quatro servidores — e três deles passariam a maior parte do dia ociosos.

Multilocação (*multitenancy*)

Vários clientes — os "inquilinos" (*tenants*) — dividem o mesmo equipamento físico **sem saber um do outro** e sem conseguir alcançar os dados um do outro.

A analogia: um prédio de apartamentos. Mesma fundação, mesmo elevador, mesma entrada de energia, mesma equipe de limpeza. Apartamentos separados, chaves separadas, contas de luz separadas. Ninguém constrói um prédio inteiro para morar sozinho — sairia caro demais.

O que garante a separação

- O hipervisor, que não deixa uma máquina virtual ler a memória da outra
- Isolamento de rede: cada cliente enxerga só a própria rede
- Criptografia do disco e do tráfego
- Auditoria e certificação independentes do provedor

O efeito colateral: vizinho barulhento (*noisy neighbor*)

- Um inquilino consome muito mais que o previsto e degrada o desempenho dos outros na mesma máquina
- Os provedores combatem com cotas, limites de uso e instâncias dedicadas — que custam mais

Sem dividir o equipamento não existe economia de escala. O preço baixo da nuvem é o aluguel de uma fração de máquina, não o aluguel de uma máquina.

Máquina virtual e contêiner: onde passa o corte

	MÁQUINA VIRTUAL (VIRTUAL MACHINE)	CONTÊINER (CONTAINER)
O que ela virtualiza	O hardware inteiro	O sistema operacional
O que carrega junto	Um sistema operacional completo, com tudo o que ele traz	Só a aplicação e as bibliotecas dela; o núcleo (kernel) é o do hospedeiro, compartilhado
Tempo para subir	Segundos a minutos	Milissegundos
Quantos cabem por servidor	Dezenas	Centenas, às vezes milhares
Isolamento	Forte: a fronteira é o hipervisor	Menor: a fronteira é o próprio sistema operacional
Quando usa	Quando a carga precisa de um sistema operacional próprio, ou de isolamento máximo	Quando a aplicação sobe e desce o tempo todo e precisa de densidade

Nuvem não é sinônimo de contêiner. Contêiner é uma técnica de empacotamento que existia antes e que a nuvem popularizou por um motivo econômico: mais aplicações por servidor significa menos servidores para o mesmo trabalho, e menos servidores significa preço menor por aplicação.

Esse raciocínio volta na Aula 7, quando a unidade de cobrança deixar de ser a máquina e passar a ser a execução de uma função.

Multiplexação estatística

Dividir um recurso compartilhado entre muitos usuários aproveitando o fato de que **eles não usam o recurso ao mesmo tempo**. *statistical multiplexing*

A ideia não nasceu na nuvem: vem das telecomunicações. É a mesma razão pela qual a operadora nunca precisou de uma linha física por assinante, e pela qual o banco não guarda em caixa todo o dinheiro depositado.

Cada cliente tem o seu pico em um momento diferente. A loja pica ao meio-dia; o sistema acadêmico, na semana da matrícula; a contabilidade, no fim do mês.

O pico da soma é muito menor que a soma dos picos. Quando as demandas são somadas, os vales de um cobrem os picos do outro.

Quanto mais clientes, e mais diferentes entre si, mais estável fica a demanda agregada. É a lei dos grandes números fazendo o trabalho.

Resultado: o provedor opera com utilização média alta. O seu servidor, dimensionado para o seu pico, opera com utilização média baixa — e você paga o ano inteiro por uma capacidade que usa em duas semanas.

ARMBRUST, M. et al. A View of Cloud Computing. Communications of the ACM, v. 53, n. 4, p. 50-58, 2010.

O artigo de Berkeley que nomeou as três novidades econômicas da nuvem: recursos infinitos, fim do compromisso antecipado e pagamento de curto prazo.

Cinco clientes, cinco picos, um único parque de servidores

CLIENTE	QUANDO É O PICO DELE	SERVIDORES NO PICO	MÉDIA DO DIA
Loja virtual	Meio-dia e das 20h às 22h	100	20
Sistema acadêmico	Madrugada de abertura da matrícula	80	10
Escritório de contabilidade	Do dia 1 ao dia 5, e o fechamento do mês	60	15
Serviço de vídeo regional	Das 21h às 23h	120	30
Aplicativo de entrega	Das 19h às 21h e domingo à noite	90	25
Soma (se cada um comprar para o próprio pico)		450	100

450

servidores comprados, se cada empresa montar o próprio parque para o próprio pico

~180

servidores bastam no provedor, porque os cinco picos acontecem em horas diferentes

22%

é a utilização média de quem compra para o próprio pico: 100 usados de 450 comprados

A economia de escala da nuvem não vem de comprar servidor mais barato. Vem de comprar *menos* servidor para o mesmo trabalho. O desconto de volume que a Amazon consegue com o fabricante é a menor parte da conta.

Números didáticos, construídos para a aula: ilustram a mecânica da multiplexação estatística, não medem um provedor real.

Dimensionar capacidade: três cenários, dois erros

Superprovisionado (*over-provisioning*)

A capacidade fica acima da demanda o tempo todo. Você paga por máquina parada. **É o estado normal de um parque próprio**, porque ele foi comprado para o pior dia do ano.

Subprovisionado (*under-provisioning*)

A demanda passa da capacidade. O sistema fica lento ou sai do ar — justamente na hora em que mais gente queria usar. O prejuízo não aparece na fatura: aparece na receita.

Elástico (*elastic*)

A capacidade sobe e desce junto com a demanda, sozinha. Você paga perto do que usou. A folga existe, mas é fina — cobre o tempo que o sistema leva para reagir.

O erro caro não é o servidor ocioso. Servidor ocioso custa dinheiro, e dinheiro se calcula. Cliente que tentou comprar e não conseguiu custa a venda, custa a reputação, e não volta na semana seguinte para tentar de novo.

Os três cenários são a figura clássica de Armbrust et al., A View of Cloud Computing, CACM 53(4), 2010.

Escalável não é a mesma coisa que elástico

Escalabilidade (*scalability*) é a capacidade de o sistema atender mais carga quando recebe mais recurso. Elasticidade (*elasticity*) é esse ajuste acontecer **sozinho, nos dois sentidos, no tempo da demanda**.

Crescer para cima — vertical (*scale up*)

- A mesma máquina fica maior: mais processador, mais memória
- Simples: a aplicação não precisa mudar
- Tem teto físico — existe uma máquina maior de todas
- Quase sempre exige desligar para trocar

Crescer para o lado — horizontal (*scale out*)

- Entram mais máquinas iguais, dividindo o trabalho
- Sem teto prático: é assim que a nuvem funciona
- Exige a aplicação preparada — sem guardar estado na máquina
- Exige algo distribuindo a carga entre elas

Um sistema pode ser escalável **e não ser elástico**: se alguém precisa clicar em um botão para crescer, não é elástico. Se cresce mas não encolhe depois do pico, também não é — e é aí que mora boa parte das faturas altas.

Só a elasticidade vira dinheiro. Crescer sem encolher é apenas gastar mais devagar do que comprar.

Elasticidade rápida (*rapid elasticity*) é a característica 4 do NIST. Serviço medido (*measured service*), a quinta, é o que permite cobrar por ela.

O sistema acadêmico da faculdade lota em uma semana do semestre e fica quase parado no resto do ano.

Comprar servidor para aguentar essa semana é prudência ou desperdício?

E a pergunta que vem depois: se a matrícula sair do ar por duas horas, quanto isso custa? Some o suporte, a coordenação, o retrabalho da secretaria e o aluno que desistiu. Compare esse número com o preço de deixar os servidores ligados o ano inteiro.

O que sustenta o preço

01 Virtualização

Um servidor físico vira muitos servidores lógicos. Sem isso, nada do resto existe.

02 Multilocação

Muitos clientes dividem o mesmo equipamento, isolados uns dos outros. O aluguel é de uma fração de máquina.

03 Multiplexação estatística

Como os picos não coincidem, o provedor precisa de menos servidor que a soma dos parques individuais.

04 Elasticidade

A capacidade acompanha a demanda sozinha, nos dois sentidos. É o que transforma economia técnica em economia na fatura.

A nuvem não é barata por bondade nem por magia. É barata porque **a utilização média dela é alta** e a do seu servidor é baixa.

02

BLOCO 2

O preço

Despesa de capital contra despesa operacional, custo total de propriedade, os quatro modelos de compra e os quatro lugares por onde a fatura vaza. A partir daqui a conversa deixa de ser sobre tecnologia e passa a ser sobre decisão.

Despesa de capital e despesa operacional

CAPEX (*capital expenditure*) — dinheiro gasto para adquirir um bem que vai durar anos. Vira patrimônio e é depreciado ao longo da vida útil, tipicamente 3 a 5 anos para um servidor.

OPEX (*operational expenditure*) — dinheiro gasto para manter a operação funcionando. É despesa do mês em que aconteceu.

	SERVIDOR PRÓPRIO — CAPITAL	NUVEM — OPERACIONAL
Quando você paga	Tudo de uma vez, antes de usar	Todo mês, depois de usar
Quem precisa aprovar	Diretoria, comitê de investimento, às vezes o conselho	O próprio time, com cartão corporativo
Prazo até estar de pé	Semanas ou meses: cotação, compra, entrega, instalação	Minutos
Se você errar para mais	Custa uma vez e dói por anos, com o equipamento parado	Custa todo mês — e quase ninguém percebe, porque a fatura chega parecida com a do mês passado
Se você errar para menos	Nova compra, novo prazo, nova aprovação	Ajusta no mesmo dia

O ponto que não é contábil: trocar capital por despesa muda quem decide. Comprar servidor é um projeto com dono e assinatura; ligar um recurso na nuvem é um clique de qualquer pessoa do time. A conta ficou mais flexível e, ao mesmo tempo, mais fácil de estourar sem que ninguém tenha decidido estourá-la.

Custo total de propriedade

TCO (*total cost of ownership*) — tudo o que custa **ter** o recurso ao longo da vida útil dele, e não apenas comprá-lo. Comparar preço de compra com fatura mensal é comparar coisas diferentes.

SERVIDOR PRÓPRIO

O que não está na nota fiscal

- Energia elétrica, ligada 24 horas por dia
- Refrigeração, que custa quase tanto quanto a energia do servidor
- Espaço físico, controle de acesso e segurança
- Link de internet dedicado e redundância
- Licenças de sistema operacional e de virtualização
- Equipe de infraestrutura, plantão e treinamento
- Peça de reposição, garantia, troca ao fim da vida útil
- Ociosidade: a capacidade comprada para o pico e não usada
- Custo de oportunidade: o dinheiro parado no servidor não está no produto

NUVEM

O que também não está na fatura

- Gente que sabe operar a plataforma — e que custa mais caro no mercado
- O tempo de aprendizagem da equipe até parar de errar
- Ferramentas de monitoramento e de gestão de custo
- Tráfego de saída, que só aparece quando o volume cresce
- O custo de sair depois, se um dia quiser sair

Honestidade intelectual: a nuvem também tem custo escondido. A diferença é que o dela chega todo mês, em número.

Regra para a discussão: ninguém compara TCO comparando o preço do servidor com a fatura do mês. Compara-se o custo acumulado das duas opções ao longo do mesmo período — normalmente três anos, que é a vida útil contábil típica do equipamento.

Quatro formas de comprar a mesma máquina

MODELO	COMO FUNCIONA	PREÇO	QUANDO USAR
Sob demanda (on-demand)	Paga por segundo ou hora ligada, sem nenhum compromisso. Liga e desliga quando quiser.	O mais caro por hora	Carga imprevisível, curta, ou que você ainda está descobrindo
Reservado / plano de economia (reserved · savings plan)	Você se compromete com um consumo por 1 ou 3 anos e paga menos por hora, use ou não use.	Desconto grande	A carga que você tem certeza de que vai existir daqui a um ano
Capacidade ociosa leiloadada (spot)	Você usa a capacidade que sobrou no provedor. Ele pode tomar de volta com poucos minutos de aviso.	O mais barato	Trabalho que pode ser interrompido e refeito: lote, renderização, treino de modelo
Nível gratuito (free tier)	Cota mensal sem custo, dentro de limites definidos pelo provedor.	Zero, dentro da cota	Aprendizado, teste e as práticas desta disciplina

Por que o desconto existe? Porque o seu compromisso reduz a incerteza do provedor. Com menos incerteza, ele precisa manter menos capacidade de reserva parada — e divide com você o que economizou. É a multiplexação estatística de novo, agora escrita em forma de contrato.

Os quatro lugares por onde a fatura vaza

01

Tráfego de saída (*egress*)

Colocar dado dentro do provedor é gratuito. Tirar, não. Vale para todos os provedores, e é o item que quase ninguém coloca na estimativa.

02

Recurso zumbi

Ambiente de teste que ficou ligado, disco de máquina apagada, endereço reservado sem uso. Ninguém desliga porque ninguém sabe de quem é.

03

Superdimensionamento

Máquina dez vezes maior que o necessário, escolhida no "vai que precisa". A folga preventiva do parque próprio perdeu o sentido — mas o hábito ficou.

04

Cópia de segurança sem prazo (*backup*)

Rotina que guarda tudo e nunca apaga nada. Cresce todo dia, para sempre, diluída em centavos por gigabyte até virar uma linha grande.

29%

do gasto com nuvem é considerado **desperdício pelas próprias empresas** que o pagam. Gerir custo é, há vários anos seguidos, o desafio número 1 declarado por elas.

Flexera, State of the Cloud Report 2026

Nenhum dos quatro é falha técnica. Todos são falha de gestão — e é exatamente por isso que nasceu uma disciplina inteira para tratar disso.

FinOps: a resposta organizacional

Prática de gestão financeira da nuvem que coloca **engenharia, finanças e negócio na mesma decisão**. O nome vem de *Finance* + *Operations*, na mesma lógica de DevOps.

A premissa que muda tudo: quem cria o custo é a pessoa que escreve o código, no instante em que escolhe o tamanho da máquina — não o setor financeiro, no fim do mês, olhando um boleto que ele não sabe explicar.

FASE 1

Informar (*inform*)

- Visibilidade do gasto, em tempo quase real
- Marcação de recursos por time, produto e ambiente
- Cada real com um dono identificado

FASE 2

Otimizar (*optimize*)

- Desligar o que não é usado
- Redimensionar o que está grande demais
- Comprometer o que é estável, para pegar desconto

FASE 3

Operar (*operate*)

- Transformar em rotina, não em mutirão
- Metas de custo por unidade entregue
- Responsáveis nomeados e revisão periódica

FinOps Foundation · STORMENT, J. R.; FULLER, M. Cloud FinOps: collaborative, real-time cloud value decision making. 2. ed. O'Reilly, 2023.

Se a fatura é criada por quem escreve o código, de quem é a responsabilidade de reduzi-la?

Na Aula 2 nós vimos que a configuração é sempre da coluna do cliente — e que quase todo vazamento nasce ali. O custo segue exatamente a mesma lógica: o provedor cobra pelo que foi ligado, e quem liga é o time de desenvolvimento.

Uma segunda pergunta, mais desconfortável: o desenvolvedor da sua equipe sabe quanto custa por mês a máquina que ele acabou de criar? Se a resposta é não, de quem é a culpa quando a fatura chega?


BLOCO 3

A decisão de migrar

O ponto de equilíbrio entre as duas contas, as sete estratégias de migração de sistemas legados, e o argumento de quem diz que a nuvem, passado certo tamanho, deixa de compensar.

Ponto de equilíbrio (*break-even point*)

O momento em que o **custo acumulado** das duas opções se iguala. Antes dele, uma é mais barata; depois, a outra. A pergunta nunca é "o que é mais barato", e sim "mais barato até quando".



Tende ao parque próprio

- Carga previsível
- Constante, sem picos relevantes
- De longo prazo, madura
- Equipe própria capaz de operar

Tende à nuvem

- Carga variável ou sazonal
- Crescimento incerto
- Projeto curto ou experimento
- Precisa estar em outro país amanhã

O que quase sempre falta na conta de quem defende o parque próprio: o salário da equipe que opera, o tempo até o servidor chegar e ser instalado, e o custo de ter errado o tamanho. Os três desaparecem da planilha justamente porque não vêm em nota fiscal.

As sete estratégias de migração de sistemas legados

ESTRATÉGIA	O QUE É	QUANDO SE ESCOLHE	ESFORÇO
Retire — aposentar	Desligar o sistema. Ele não vai para lugar nenhum.	O inventário revelou um sistema que ninguém usa e ninguém assume	Mínimo
Retain — manter onde está	Não migrar agora. É uma decisão, não uma omissão.	Exigência legal, contrato vigente, ou sistema que será desligado em breve	Nenhum
Rehost — re-hospedar	Mover como está, sem mudar nada. Lift and shift: levantar e mudar de lugar.	Prazo curto, contrato do data center vencendo, muitos servidores de uma vez	Baixo
Relocate — realocar	Mover a plataforma inteira para a versão dela que roda na nuvem.	Parque virtualizado com equivalente hospedado pelo provedor	Baixo
Repurchase — recomprar	Trocar o sistema por um produto pronto. Drop and shop: largar e comprar.	Sistema comprado que já tem uma versão como serviço no mercado	Médio
Replatform — mudar de plataforma	Mover com ajustes pontuais, sem reescrever. Lift, tinker and shift.	Trocar o banco instalado na máquina por um banco gerenciado	Médio
Refactor — refatorar	Reescrever para o modelo da nuvem: serviços, filas, funções, escala automática.	O sistema é o produto da empresa e precisa crescer sem limite	Alto

AWS Prescriptive Guidance, Migration strategies. · Linhagem do modelo: 5 R’s da Gartner (Richard Watson, 2010) -> 6 R’s de Stephen Orban, AWS (2016) -> os 7 R’s atuais.

O paradoxo do trilhão de dólares

"Você é louco se não começar na nuvem. E é louco se ficar nela."

Sarah Wang e Martin Casado, Andreessen Horowitz, 2021

O argumento: no começo, a nuvem elimina o compromisso antecipado e compra velocidade — é uma escolha óbvia. Quando a empresa cresce e a carga fica grande e previsível, a mesma nuvem vira a maior linha do custo do produto e passa a comer a margem.

Os números do artigo

Entre empresas de software analisadas, o gasto contratado com nuvem chegou a representar, em média, **50% do custo da receita**

Os autores estimam **US\$ 100 bilhões** de valor de mercado perdidos entre 50 empresas, só pelo efeito na margem

O caso que eles citam: Dropbox

Construiu a própria infraestrutura e economizou cerca de **US\$ 75 milhões em dois anos**

Margem bruta subiu de **33% para 67%** entre 2015 e 2017

- Só funcionou porque a carga era enorme, estável e sempre a mesma: guardar arquivo

BLOCO 4

A conta de quem fez o caminho inverso

Uma empresa de software americana saiu da AWS em 2023 e publicou os números. Vamos refazer a conta dela juntos, no quadro, e depois responder a uma pergunta incômoda sobre as sete estratégias que acabamos de estudar.

37signals — Basecamp e HEY — saiu da AWS em 2023

Empresa de software com produtos maduros, base de clientes estável e carga previsível há mais de uma década. Publicou abertamente cada número da decisão, o que torna o caso raro: quase ninguém abre a fatura.

US\$ 3,2 mi

por ano de gasto com nuvem **antes** da saída

US\$ 700 mil

gastos **uma única vez** na compra do hardware próprio, em 2023

US\$ 1,3 mi

por ano de gasto **depois** da saída, em 2024

+US\$ 10 mi

é a economia que a empresa projeta em cinco anos

Antes de fazer a conta, três perguntas para a turma:

- Olhando só para esses quatro números, a decisão parece boa ou parece propaganda?
- O que precisa ser verdade sobre a carga de trabalho dessa empresa para que a conta feche assim?

O que esses números *não* mostram?

Fontes públicas: 37signals, Leaving the Cloud (basecamp.com/cloud-exit) e D. H. Hansson, "Our cloud-exit savings will now top ten million over five years" (2024).

Fazendo a conta no quadro

Gasto anual antes	US\$ 3,2 mi
-------------------	-------------

Gasto anual depois	US\$ 1,3 mi
--------------------	-------------

Economia por ano	US\$ 1,9 mi
------------------	--------------------

Investimento em hardware	US\$ 0,7 mi
--------------------------	-------------

Tempo para o hardware se pagar	~4,5 meses
--------------------------------	-------------------

Em cinco anos $(1,9 \times 5) - 0,7$	US\$ 8,8 mi
--------------------------------------	--------------------

A empresa projeta mais de US\$ 10 milhões somando também a saída do serviço de armazenamento.

Por que deu certo para eles

Carga **previsível e estável** há mais de dez anos, sem picos sazonais relevantes

- Produto maduro, que não muda de forma a cada trimestre
- Equipe própria pequena e muito capaz de operar servidores
- Sem planos de expansão para vários países

Quando essa conta se inverte

- Crescimento incerto: você não sabe se precisa de 10 ou 100 servidores no ano que vem
- Pico sazonal forte — a máquina fica parada onze meses
- Equipe pequena, sem gente para plantão de madrugada
- Necessidade de operar em outra região do mundo em semanas

Qual das sete estratégias descreve o que o 37signals fez?

Nenhuma.

As sete estratégias descrevem caminhos **para** a nuvem. Não existe um "R" para voltar. O mercado precisou inventar um termo depois, quando o movimento começou a acontecer: **repatriação** (*cloud repatriation*).

Todo vocabulário técnico carrega o interesse de quem o escreveu. Os 7 R's são excelentes, são usados no mundo inteiro — e foram publicados pela AWS. Isso não os invalida. Só significa que a ausência de um oitavo R não é esquecimento.

E o outro lado da mesma moeda: Nubank

Um dos maiores bancos digitais do mundo, com mais de cem milhões de clientes, nasceu na nuvem e continua nela — e trata eficiência de custo como **disciplina de engenharia**, com times dedicados a medir e reduzir o gasto de cada serviço, e não como um corte de despesa feito uma vez por ano.

A conclusão da aula não é "a nuvem compensa" nem "a nuvem não compensa". É que a resposta depende do formato da sua carga, do tamanho da sua equipe e do horizonte da sua decisão — e que existe uma conta que pode ser feita, em vez de uma opinião que se defende.

O que fica de hoje

PONTO	REGRA PRÁTICA
Por que a nuvem é barata	Virtualização e multilocação permitem dividir a máquina; a multiplexação estatística faz o provedor precisar de menos servidores que a soma dos parques individuais.
Escalável e elástico	Escalável é aguentar mais carga com mais recurso. Elástico é isso acontecer sozinho, nos dois sentidos. Só o segundo reduz a fatura.
Capital e operacional	Errar para mais em capital dói uma vez, por anos. Errar para mais em operacional dói todo mês, e passa despercebido.
Custo total de propriedade	Compara-se custo acumulado no mesmo período, nunca preço de compra contra fatura mensal.
A fatura que surpreende	Tráfego de saída, recurso zumbi, superdimensionamento e cópia de segurança eterna. Nenhum é falha técnica.
A decisão de migrar	Sete estratégias, e a escolha depende do formato da carga. Nenhuma delas descreve o caminho de volta.

Provisionar é metade da competência. A outra metade é **saber o que aquilo custa** — e conseguir defender a conta na frente de quem assina.

Glossário: o termo em inglês e o que ele quer dizer

Toda a bibliografia e toda a documentação de provedor estão em inglês. Guardar a tradução ao lado do termo evita decorar palavra sem conceito.

<code>hypervisor</code> hipervisor Programa que divide um servidor físico em várias máquinas virtuais
<code>virtual machine</code> máquina virtual Computador completo que existe como arquivo dentro de outro
<code>multitenancy</code> multilocação Vários clientes dividindo o mesmo equipamento, isolados
<code>noisy neighbor</code> vizinho barulhento Inquilino que consome demais e prejudica os outros
<code>container</code> contêiner Empacotamento que compartilha o núcleo do hospedeiro
<code>statistical multiplexing</code> multiplexação estatística Compartilhar recurso aproveitando que os picos não coincidem
<code>over-provisioning</code> superprovisionamento Capacidade comprada acima da demanda real
<code>under-provisioning</code> subprovisionamento Capacidade abaixo da demanda: o sistema cai

<code>scalability</code> escalabilidade Atender mais carga quando recebe mais recurso
<code>scale up</code> crescer para cima A mesma máquina fica maior (vertical)
<code>scale out</code> crescer para o lado Entram mais máquinas iguais (horizontal)
<code>elasticity</code> elasticidade O ajuste de capacidade acontecer sozinho, nos dois sentidos
<code>CAPEX</code> despesa de capital Compra de bem que dura anos e vira patrimônio
<code>OPEX</code> despesa operacional Gasto do mês para manter a operação de pé
<code>TCO</code> custo total de propriedade Tudo o que custa ter o recurso, não só comprá-lo
<code>break-even point</code> ponto de equilíbrio Momento em que os custos acumulados se igualam

<code>on-demand</code> sob demanda Paga pelo uso, sem compromisso de prazo
<code>reserved / savings plan</code> reservado / plano de economia Desconto em troca de compromisso de 1 ou 3 anos
<code>spot</code> capacidade ociosa leiloada Sobra do provedor, barata, que pode ser retomada
<code>free tier</code> nível gratuito Cota mensal sem custo dentro de limites
<code>egress</code> tráfego de saída Dado que sai do provedor — entrar é grátis, sair não
<code>FinOps</code> gestão financeira da nuvem Engenharia, finanças e negócio decidindo custo juntos
<code>lift and shift</code> levantar e mudar Migrar o sistema como está, sem alterações
<code>cloud repatriation</code> repatriação Trazer de volta para infraestrutura própria

REFERÊNCIAS

De onde veio cada afirmação desta aula

DEFINIÇÃO E FUNDAMENTOS

MELL, P.; GRANCE, T. **The NIST Definition of Cloud Computing**. NIST SP 800-145, 2011.

nvlpubs.nist.gov/nistpubs/legacy/sp/nistspecialpublication800-145.pdf

ARMBRUST, M. et al. **A View of Cloud Computing**. Communications of the ACM, v. 53, n. 4, 2010.

cacm.acm.org

MOLINARI, L. **Cloud Computing: a inteligência na nuvem e seu novo valor em TI**. Érica, 2017.

[bibliografia básica da disciplina](#)

JACKSON, K. L.; GOESSLING, S. **Architecting Cloud Computing Solutions**. Packt, 2018.

[bibliografia básica da disciplina](#)

SALESFORCE. **O que é computação em nuvem**. Panorama introdutório em português.

salesforce.com/br/platform/cloud-computing/

CUSTO, MIGRAÇÃO E O OUTRO LADO

AWS. **Migration strategies** (as 7 estratégias). AWS Prescriptive Guidance.

docs.aws.amazon.com/prescriptive-guidance

STORMENT, J. R.; FULLER, M. **Cloud FinOps**. 2. ed. O'Reilly, 2023.

finops.org

FLEXERA. **State of the Cloud Report 2026**. Adoção, gasto e desperdício.

flexera.com

WANG, S.; CASADO, M. **The Cost of Cloud, a Trillion Dollar Paradox**. a16z, 2021.

a16z.com/the-cost-of-cloud-a-trillion-dollar-paradox/

37SIGNALS. **Leaving the Cloud**. Página com todos os números da saída.

basecamp.com/cloud-exit

AWS. **Pricing Calculator** — a ferramenta que usaremos para estimar custo.

calculator.aws

Regiões, zonas de disponibilidade e o primeiro recurso no ar

Geografia da nuvem: onde os prédios ficam, por que existem várias zonas dentro de uma mesma região, o que é latência e o que é soberania de dados. E é a aula em que a prática começa — com um site publicado por vocês, no ar, com endereço público.

Para chegar pronto no dia 10

- Conta na AWS criada e funcionando
- Autenticação em duas etapas ativada na conta principal
- Usuário separado criado, com a conta raiz guardada para emergência
- Alerta de orçamento configurado em US\$ 1 — o freio antes de o carro andar

Quem ainda não tem cartão internacional para o cadastro precisa avisar hoje, para combinarmos a alternativa antes da aula.