

Serverless: a função como unidade de computação

Depois de pagar por máquina ligada (EC2) e por dado guardado (S3), o terceiro modelo: código que só roda quando um evento acontece, e só é cobrado por isso.

O que veremos hoje

BLOCO 1

O que é serverless

Quem cuida do quê quando o servidor deixa de ser problema seu, e a anatomia de uma função Lambda.

BLOCO 2

Eventos e limites

O que dispara uma função, o início a frio e os casos em que ela não serve.

BLOCO 3

Custo e arquitetura

Como a Lambda cobra, quando compensa, e como ela entra no site que a equipe já publicou.

Processar e guardar

EC2

Processa

Máquina virtual: você escolhe família, tamanho e modelo de compra. Cobra por segundo enquanto existe, mesmo parada esperando.

S3

Guarda

Objetos com chave e metadados, onze meses de durabilidade. Cobra por GB guardado, requisições e saída.

REGRA

Separar os dois

Máquina descartável, dado no S3. É o que permite escalar. E o site estático da equipe ficou no S3, sem servidor.

O site estático entrega páginas prontas. Mas e quando a página precisa **calcular** ou **responder** algo? Ligar uma EC2 para isso seria voltar à máquina ociosa da Aula 3.

Três jeitos de pagar pela nuvem

Cada modelo cobra por uma coisa diferente. Hoje entra o terceiro.

AULA 3 · RESPONDIDO

Por que a nuvem é barata?

Multiplexação: muitos clientes dividem o mesmo parque, e cada um paga pelo uso.

AULA 5 · RESPONDIDO

Pagar por máquina ligada

EC2: o relógio corre enquanto a instância existe.

AULA 6 · RESPONDIDO

Pagar por dado guardado

S3: GB por mês, requisições e saída de dados.

HOJE · EM ABERTO

Pagar só pela execução

Lambda: milissegundos de código rodando, e nada quando ninguém chama.

Quanto mais fina a unidade de cobrança, menos se paga por capacidade parada.

Da máquina ao objeto, do objeto à execução.

PERGUNTA DE ABERTURA

O site da equipe ganhou um formulário de contato que recebe umas três mensagens por dia. Vale ligar uma EC2 24 horas só para processar essas três mensagens?

A máquina passaria mais de 23 horas e 59 minutos por dia esperando. A pergunta desta aula é: dá para pagar só pelos segundos em que o código de fato trabalha?

01

BLOCO 1

O que é serverless

O servidor continua existindo. Ele só deixa de ser problema seu.

Serverless e função como serviço

Serverless é o modelo em que o provedor executa o seu código em resposta a eventos, escala sozinho e cobra só pelo tempo de execução. A forma mais comum é a função como serviço (FaaS), que na AWS se chama Lambda.

NA LITERATURA

Jonas et al., Berkeley, 2019

O mesmo grupo de Berkeley do artigo de 2010 (Aula 3) descreve o serverless como a próxima simplificação da nuvem: o programador não provisiona nem administra servidores, e paga pelo que usa, não pelo que reserva.


O NOME ENGANA

Sem servidor, não

Há servidores, e muitos. "Serverless" quer dizer que você não os vê, não os escolhe, não os atualiza e não paga por eles parados.

JONAS, E. et al. Cloud Programming Simplified: A Berkeley View on Serverless Computing. UC Berkeley, Technical Report EECS-2019-3, 2019.

Quanto é seu em cada camada



Na Lambda você entrega só o código. Quem escala, atualiza e liga o servidor é a AWS, e só quando chega um evento.

Retoma a pilha de responsabilidades da Aula 2. A Lambda fica entre a plataforma e o software pronto: você só escreve a função.

A anatomia de uma função Lambda

Peça	O que é	No exemplo de hoje
Handler	A função que a Lambda chama a cada evento	lambda_handler(event, context)
event	Os dados de quem chamou	A requisição que veio do navegador
Runtime	A linguagem e a versão que rodam o código	Python 3.13
Memória	De 128 MB a 10.240 MB; a CPU cresce junto	128 MB bastam
Papel (role)	As permissões da própria função	Só escrever logs no CloudWatch

AWS. Lambda Developer Guide: Lambda function handler in Python; Configuring function memory.

A função da equipe, inteira

```
LAMBDA_FUNCTION.PY

1 import json
2 from datetime import datetime, timezone, timedelta
3
4 def lambda_handler(event, context):
5     agora = datetime.now(timezone(timedelta(hours=-3)))
6     return {
7         "statusCode": 200,
8         "headers": {"Content-Type": "application/json"},
9         "body": json.dumps({
10             "mensagem": "Olá da Lambda da Equipe 3!",
11             "horario": agora.strftime("%H:%M"),
12         }),
13     }
```

CONFIRA É Python comum, como na disciplina de Coding: uma função que recebe dados e devolve um dicionário. A Lambda transforma esse dicionário na resposta HTTP.

O que o navegador recebe às 19h05?



RESPOSTA DA URL DA FUNÇÃO

- 1 # a função acima foi chamada pelo navegador às 19h05 de Caruaru
- 2 # 1) qual é o código HTTP da resposta?
- 3 # 2) o que aparece na tela?

Código 200 e um JSON



RESPOSTA DA URL DA FUNÇÃO

```
1 HTTP/1.1 200 OK
2 Content-Type: application/json
3
4 {"mensagem": "Olá da Lambda da Equipe 3!", "horario": "19:05"}
```

CONFIRA O statusCode vira o código HTTP, os headers viram cabeçalhos e o body é o texto entregue. É isso que o JavaScript do site vai ler.

O que define o serverless

- | | | |
|----|-----------------------------|--|
| 01 | Você entrega código | Sistema, servidor e escala ficam com o provedor. |
| 02 | A função é a unidade | Handler, evento, runtime, memória e permissões. |
| 03 | Paga pela execução | Sem chamada, sem cobrança. |

Se ela só roda quando algo acontece, a pergunta seguinte é: o que pode acontecer?

BLOCO 2

Eventos e limites

Uma função não fica esperando: ela é acordada por um evento, faz o trabalho e some.

Programação orientada a eventos



Sem evento, nada roda e nada é cobrado. O event traz os dados de quem chamou: a URL, o arquivo, o horário.

Os quatro gatilhos mais comuns. A mesma função pode responder a um navegador, a um arquivo novo, a um relógio ou a uma fila.

Gatilho e cenário

Gatilho	Cenário	O que a função faz
URL da função (HTTP)	Formulário de contato do site da equipe	Valida e responde em JSON
Upload no S3	Usuário envia uma foto de perfil (Aula 6)	Gera uma miniatura e grava no S3
Agendamento	Todo dia às 8h	Monta o relatório de vendas do dia anterior
Fila (SQS)	Pedidos chegando na Black Friday	Processa um pedido por vez, sem perder nenhum

AWS. Lambda Developer Guide: Invoking Lambda with events from other AWS services.

Sem estado: a lição da Aula 6, levada ao limite

Cada execução pode rodar num ambiente novo, e nada garante que a próxima encontre o que a anterior deixou na memória ou no disco. Por isso a função não guarda estado: o que precisa durar vai para o S3 ou para um banco.

NA AULA 6

Máquina descartável, dado no S3

Era a regra para escalar a EC2 na Black Friday. Na Lambda ela deixa de ser recomendação e vira obrigação.

O ERRO COMUM

Contar visitas numa variável

Um contador global parece funcionar no teste e "zera sozinho" depois. O contador certo mora fora da função.

O início a frio

1ª chamada

início a frio

prepara o ambiente

carrega o código

executa

Por que importa

O primeiro usuário espera mais. Para um formulário de contato, tanto faz. Para um pagamento com tempo limite, pode fazer diferença.

2ª chamada

segundos depois

executa

o ambiente ainda está quente: resposta rápida

Depois de um tempo parada

prepara o ambiente

carrega o código

executa

tempo

Início a frio (cold start): a AWS precisa preparar um ambiente novo antes de rodar a sua função pela primeira vez.

Na primeira chamada, ou depois de um tempo parada, a AWS precisa preparar um ambiente. As chamadas seguintes reaproveitam o ambiente quente.

Os limites que decidem se a Lambda serve

Limite	Valor	O que isso exclui
Tempo máximo de execução	15 minutos	Processamentos longos, como renderizar um vídeo inteiro
Memória	128 MB a 10.240 MB	Cargas que precisam de muita memória numa máquina só
Estado	Nenhum entre execuções	Guardar sessão ou arquivos no próprio ambiente
Início a frio	Atraso na primeira chamada	Respostas que não toleram nenhuma espera

AWS. Lambda Developer Guide: Lambda quotas.

Lambda ou não?

Cenário	Sua escolha
A. Responder ao formulário de contato do site da equipe	?
B. Renderizar um filme de duas horas, quadro a quadro, num só processo	?
C. Gerar a miniatura de cada foto enviada a um bucket	?
D. Um servidor de jogo com 200 jogadores conectados o tempo todo	?

Lambda ou não?

Cenário	Escolha	Por quê
A. Formulário de contato	Lambda	Poucas chamadas, curtas, sem estado
B. Filme de duas horas	EC2 (ou Spot)	Passa dos 15 minutos de execução
C. Miniatura de fotos	Lambda	Evento do S3, trabalho curto, escala sozinho
D. Servidor de jogo	EC2 ou contêiner	Conexões contínuas e estado em memória

Quando a função faz sentido

- | | | |
|----|---------------------------|---|
| 01 | Há um evento | URL, arquivo, horário ou fila acordam a função. |
| 02 | O trabalho é curto | Segundos, no máximo 15 minutos. |
| 03 | Não guarda estado | O que precisa durar vai para S3 ou banco. |

E quanto custa? A resposta depende de quantas vezes o evento acontece.

03

BLOCO 3

Custo e arquitetura

A conta da Lambda e o lugar dela no site que a equipe já publicou.

Como a Lambda cobra

Duas parcelas: o número de requisições e a duração, medida em GB-segundo (memória configurada vezes o tempo de execução). Todo mês, um milhão de requisições e 400 mil GB-segundo estão no nível gratuito.

TABELA PÚBLICA

us-east-1, arquitetura x86

US\$ 0,20 por milhão de requisições e US\$ 0,0000166667 por GB-segundo, além do nível gratuito.


A CONTA DA EQUIPE

3.000 chamadas no mês

$3.000 \times 0,125 \text{ GB} \times 0,2 \text{ s} = 75 \text{ GB-segundo}$. Bem abaixo dos 400 mil gratuitos: custo zero.


AWS. AWS Lambda pricing. aws.amazon.com/lambda/pricing, consultado em 01/10/2026.

Quem sai mais barato



O mesmo raciocínio do ponto de equilíbrio da Aula 3: carga baixa e irregular favorece a Lambda; carga alta e constante volta a favorecer a máquina.

A arquitetura do projeto, hoje



O site continua no S3. O JavaScript da página chama a URL da função, que responde em JSON. Cada execução deixa um registro no CloudWatch.

Responsabilidade compartilhada, na Lambda

A AWS responde por	Você responde por
Servidores, sistema operacional e atualizações	O código da função e as bibliotecas que ele usa
Escalar de zero a milhares de execuções	As permissões do papel (role) da função
Isolar uma função da outra	Quem pode chamar a URL: pública ou autenticada
Disponibilidade do serviço	Os dados que a função recebe, grava e devolve

Mesma divisão das Aulas 1 e 2: segurança DA nuvem é do provedor; segurança NA nuvem é sua. Uma URL pública pode ser chamada por qualquer pessoa, e cada chamada conta.

O que fica de hoje

Ponto	Regra prática
Serverless	O servidor existe, mas não é problema seu: você entrega a função.
Evento	Sem evento, nada roda e nada é cobrado.
Sem estado	O que precisa durar mora no S3 ou num banco.
Limites	Até 15 minutos por execução, e início a frio na primeira chamada.
Custo	Requisições mais GB-segundo; poucas chamadas cabem no nível gratuito.

Máquina para o que roda sempre, objeto para o que se guarda, função para o que acontece de vez em quando.

A primeira função da equipe, ligada ao site

- | | | |
|----|--------------------------------|--|
| 01 | Criar e testar a função | Lambda em Python, com o código do slide, testada no próprio console. |
| 02 | Abrir uma URL pública | URL da função com CORS liberado para o site chamar. |
| 03 | Ligar ao site no S3 | Um trecho de JavaScript no index.html mostra a resposta da função. |
| 04 | Ver os logs e o custo | CloudWatch e uma linha nova no relatório de custo. |

Dois caminhos, como no Roteiro Completo: pela interface (Caminho A) ou pelo CloudShell (Caminho B).

Site no S3 e relatório de custo

- | | | |
|----|-------------------------------|--|
| 01 | Site no ar | Endereço público do S3 funcionando, com index.html e error.html. |
| 02 | Prints da configuração | Hospedagem estática ligada e política do bucket, sem chaves nem dados sensíveis. |
| 03 | Relatório de custo | Tamanho dos arquivos, estimativa na calculadora da AWS, Billing e plano de desligamento. |

Quem ligar a Lambda hoje acrescenta uma linha no relatório: chamadas esperadas e custo estimado.

REFERÊNCIAS

De onde veio cada afirmação desta aula

SERVERLESS E LAMBDA

JONAS, E. et al. Cloud Programming Simplified: A Berkeley View on Serverless Computing. UC Berkeley, 2019.

definição de serverless

AWS. Lambda Developer Guide: handler em Python; memória; cotas.

anatomia da função e limites

AWS. Lambda Developer Guide: Invoking Lambda with events from other services.

gatilhos

CUSTO E ACESSO

AWS. AWS Lambda pricing. aws.amazon.com/lambda/pricing.

requisições, GB-segundo e nível gratuito

AWS. Lambda Developer Guide: Control access to Lambda function URLs.

URL pública e permissões

ARMBRUST, M. et al. A View of Cloud Computing. CACM, 2010.

ponto de equilíbrio (Aula 3)
